25级RDCAI组一轮考核

写在最前

欢迎各位参加咱们的RDCAI组的招新考核！！希望各位学有所成！！

一轮考核大约持续三周，估计在4.14-4.16进行验收与答辩，具体时间会在群内公布

考虑到AI为大家带来了学习上的不少便利，本次考核确实布置了较多学习任务与考核任务。作为筛选作用的考核，我们当然是想选择在规定时间内能够且能较好地学习更多知识、完成更多任务的同学，但也希望大家不要有很大的压力，应当将考核任务当作自己学习的动力（师兄师姐们都是这样滴），让自己更加自律。同时，希望大家可以高效、有效地利用好大语言模型辅助自己进行学习，期待各位在一轮考核上的表现，更期待与各位正式在RDC相见！

本次考核采用分数定量分析大家的学习成果，具体分值在后面的考核任务中都有说明。

一些学习提示：

1. 学会上网搜索资料，并总结、整合成你的内容。国内在csdn和知乎上，国外在Github和StackOverFlow上有非常多的大佬。
2. 学会使用AI。如chatgpt、claude、grok（思维链很强），国内的deepseek，豆包等等。但是不要过度依赖AI！这里指的“学会”是指要知道怎么问ai（你的prompt，即提示词），怎么组织你的问题以及怎样让ai理解你的问题。
3. 学会使用 markdown语法做笔记。推荐使用群内发的typora软件编辑你的笔记内容，也可以使用飞书的文档来编辑。喜欢捣鼓的同学也可以尝试Notion，Obsidian等工具。

一些特别好用的工具推荐：（适合自己的才是最好的）

1. Everything：功能强大的文件检索工具，能快速找到本地文件，提升效率
2. LaTex & Overleaf：LaTex具有强大的数学公式排版能力以及强大的标准化复刻能力，能帮助你快速写出论文，并且markdown中的数学公式就需要latex格式，推荐使用Simpletex这个网站将公式转换为latex，慢慢的你也会编辑latex了。网址：公式识别
3. Zlibrary：全世界最大的电子书网站，教材，学习资料都可以先到上面检索一下
4. DeepL：强推！翻译软件，配合英文文献食用效果更佳
5. Kaggle：Kaggle是一个全球领先的数据科学和机器学习竞赛平台，上面有很多数据集以及开源方案，还可以薅免费算力

环境配置

> 想要有一个好的学习和开发环境，在开始学习之前的环境配置工作一定要做好，在这方面，网上有很多资料供大家参考（东西能不装在C盘就别装在C盘）

大伙可以自行上网搜索以下软件的安装和配置环境教程，均很详细，如确有困惑可在群里询问师兄师姐

- Anaconda（一个非常强大的包管理工具）
- 包含了conda、Python等180多个科学包及其依赖项，可以用于创建虚拟环境，便于不同项目 的切换（建议都装）
- 编译器：（选一个即可）
  - Pycharm：Jetbrains系列的软件，功能多好用，但是专业版要付费（可以申请大学生免费，但是要等比较久），也可以上网找破解教程
  - Vscode：免费，插件多
  - Jupyter：Anconda装好后就能使用，比pycharm配置要简单不少，现在我用的也是这个比较多，推荐使用这个来写代码，可以分块执行（当然用别的也可以，其次推荐pycharm，pycharm里面也有jupyter的插件）
  - ...
- 数据库MySQL（可以要用到时再装）
- 数据库可视化工具（可以要用到时再装）

自主学习建议

以下内容均为25级RDCAI组的寒假训练营内容，没有参加过训练营的uu&0基础的可以按着下面的学习路线进行学习，同时，我们也保留了训练营中的小考核内容和数据集（群文件），大家可以在自主学习之后尝试完成小考核检验自己的学习情况。这份学习路线（第一节到第三节）原定3周内学完，但是对于目前仍0基础的同学可能需要自主加快学习进度才能完成一轮考核的任务（0基础也不要怕！付出了就一定有收获！！）。另请注意，这些小考核不是一轮考核的验收任务，仅为选做，且做了不加分，请大家按自己需要来完成。

第一节 Python与三大库

> 人生苦短，我用python。AI领域的首选语言就是python，所以大家首先需要打好python语法基础。
> 除此以外，人工智能旨在让机器模拟人类的智能行为，通过对大量数据的学习和分析，实现诸如识别、推理、决策等任务。而涉及到大量数据，其关键就是数据处理与可视化以理解与分析数据，帮助我们从原始数据中提取有价值的信息，为后续模型构建做准备。因此，我们还需要对数据分析的三大库有一定基础。（这三大库同时也是大家后续参加数模比赛的基础！！可谓是一举两得！！）

Python基本内容

1. 条件控制、循环控制语句
2. 函数
3. Python数据容器（列表、元组、字典、集合）

4. 面向对象（重点）

三大库基本内容

1. numpy：数组创建与操作；数学运算；广播机制；随机数生成
2. pandas：掌握 `series` 和 `DataFrame` 这两种核心数据结构；数据读取与写入；数据清洗与预处理；数据合并与重塑
3. matplotlib：基本图表绘制；设置图表样式（如matplotlib本身是不支持中文字符的，网上有教程设置中文）；将数据可视化以便于直观分析

学习资料

- b站很多视频可以快速看看（有c语言基础应该是不需要细看的）例如：[小甲鱼]零基础入门学习Python
- 《Python编程 从入门到实践》：蟒蛇书，经典Python教程
- CS 61A: Structure and Interpretation of Computer Programs UC Berkeley 使用 Python教授计算机科学基础概念以及编程思想的经典课程
- 菜鸟教程Python3 教程 | 菜鸟教程
- 刷题
  - 自己找题目，比如学习视频中的题目
  - Leetcode、Github、Luogu等常见社区
  - 计院的同学可以尝试用Python去完成Anyview里面的题目 （后面偏难一点的题目更好）
- 三剑客参考资料
  - Python数据分析三剑客 数学建模基础 numpy、pandas、matplotlib
  - numpy文档
  - pandas文档
  - matplotlib文档

小考核

数据集见群内文件“第一周小考核.csv”。

1. 统计数据集中不同性别的数量；
2. 筛选出年龄大于40且抽烟（smoking列值为1）的样本，并计算这些样本的BMI平均值；
3. 选用你认为合适的可视化方法，绘制一个图表，展示三种不同心脏病风险人群的年龄分布情况。

小考核（进阶版）

数据集见群内文件。本数据集选自2024年数模c题，你就是下一个数模领域大神！

1. 针对整个表格：有些作物的销售单价范围跨度较大。找出销售单价范围跨度（最高销售单价 - 最低销售单价）最大的三种作物；
2. 针对表格的序号1-30：计算并输出每种作物在平旱地和梯田两种地块类型下，每亩地的利润范围（利润 = 亩产量 * 销售单价 - 种植成本）。将结果以清晰的表格形式展示，表格包含作物名称、地块类型、最低利润和最高利润。说明哪种作物在哪种地块类型下可能获得的利润最高；
3. 针对整个表格：使用合适的可视化工具，绘制一个图表，展示不同作物在不同地块上的亩产量对比。要求图表具有清晰的标题、坐标轴标签和图例，以便直观地看出不同地块类型对各种作物亩产量的影响。

第二节 数学基础与线性回归算法

> 本节内容分为两大块：机器学习算法的前置数学基础和开始学习机器学习有关内容。
>
> 由于机器学习涉及到大家还没有学过的线性代数和高数下的知识，所以大家需要先快速学一下数学理论基础。

前置内容

1. 学习高数下多元函数，尤其是偏导数部分，不需要学得太深，了解其意义、会求偏导即可；
2. 学习线性代数中的矩阵，行向量和列向量，知道矩阵之间的四则运算，以及矩阵的逆等概念；

学习资料

1. 高等数学：
   - 【九-1】多元函数的基本概念--平面点集*哔哩哔哩*bilibili只看第九章，到全微分就好
2. 线性代数：
   - 【线性代数】2小时不挂|线代*哔哩哔哩*bilibili快速有个大概怎么运算的概念就行
   - 【-UP主汉语配音-【线性代数的本质】合集-转载于3Blue1Brown官方双语可以参考一下可视化的线性代数教程
   - 【麻省理工学院 - MIT - 线性代数（我愿称之为线性代数教程天花板）】学有余力的同学可以参考一下，但是时间有点长，做好取舍

机器学习内容

1. 了解什么是机器学习，机器学习是用来做什么的；
2. 学习经典机器学习算法之线性回归算法。包括：
   - 线性回归的两种基本方法—梯度下降法和正规方程法。学习两种方法的原理，并用代码实现；
   - 线性回归的损失函数；
   - 尝试使用python的类以及numpy库来实现代码；(原则上不允许调库实现)

学习资料

1. 《统计学习与方法》--李航
2. 刘建平Pinard - 博客园 (cnblogs.com)
3. 三个月从零入门深度学习，保姆级学习路线图*哔哩哔哩*bilibili
4. 【机器学习】【白板推导系列】【合集 1～33】 *哔哩哔哩*bilibili
5. 【(强推|双字)最新吴恩达机器学习Deeplearning.ai课程】
6. 【(强推)李宏毅2021/2022春机器学习课程】

一些提醒

1. 数学理解决定高度
2. 刘建平的博客会简略的教原理+sklearn怎么调库，但是初学者最好不要一上来就调库，建议机器学习的算法公式都能自己推导一遍理解原理，这样对自己后面的发展有好处，知道如何使用轮子，但是也要了解如何造轮子
3. 三个月从零入门深度学习那个视频，我的目的不是让你们去快餐式学，主要是希望你们能有一个整体的大局观，知道自己需要学什么，可以怎么学
4. 白板推导就是帮助你对这些算法数学公式的理解，这是一个牛人up，强烈推荐。他的视频有点散，不需要从头到尾看，你学到哪个算法，你就点哪个P看就好
5. 吴恩达的视频主要是：公式推导+代码思路，面向零基础的，所以听起来不费劲，虽然问题停留比较浅，但是现阶段足够
6. 李宏毅的视频也非常有意思，而且难度要更大一点，覆盖面很广，也可以作为后面深度学习的参考教程
7. 学有余力的同学，建议看完吴或者李的视频以后，跟着他们的homework和lab动手敲一下代码，这样既能加深理解也能提升动手能力

小考核（进阶版）

数据集见群内“第二周小考核（进阶版）.csv"。

根据这份数据集，在只使用三大库的前提下编写线性回归代码，找到Salary-YearsExperience之间的拟合直线，并用可视化图展示。

第三节 机器学习的其他知识

> 本节内容原为训练营的选学内容，在考核阶段属于必学内容，并且不限于以下内容。其他内容请大家自主搜索学习（也是考验自主学习能力的一部分）。

特征工程（重点）

> 数据和特征决定了模型的上限，而模型和算法只是逼近这个上限。特征工程应当是机器学习模型构建的最关键的步骤。特征工程直接影响模型能否捕捉到数据中的有效规律。即使使用简单模型，优秀的特征工程也能显著提升性能；反之，若特征质量差，再复杂的模型也难以发挥。

1. 明确特征工程的意义，掌握基本术语；
2. 掌握数据清洗和基础特征操作；
3. 学会从原始数据中创造新特征；
4. 学会筛选出对模型最有用的特征，减少冗余；

过拟合与正则化学习内容

1. 什么是过拟合与正则化？什么时候会发生过拟合与欠拟合？
2. 有哪些常用的正则化方法？了解它们的数学原理；

模型的评估学习内容

1. 了解训练集、测试集等概念；
2. 了解如何评估训练好的模型的性能优劣，在线性回归中有什么常用的模型评估指标；

还有其他的……请大家自主学习

学习资料

上述内容均可以自行上网搜索或查阅相关书籍来学习。

其中特征工程可见【特征工程系列】特征工程理论与代码实现 - Heywhale.com。

小考核（进阶版）

数据集见群内文件”第三周小考核（进阶版）.csv“。

1. 将原始数据集按合适的比例分成训练集和测试集；
2. 采用合适的数据预处理方法后，利用数据集进行线性回归模型的训练；
3. 训练完成后在测试集上进行测试，评估你的模型的性能优劣。

再次提醒！上述所有小考核均不是必做，且做了不加分！

第四节 机器学习之逻辑回归

> 本节内容不在原训练营之内，但在考核阶段属于必学内容。逻辑回归是一种广泛用于分类任务的统计模型，尤其适用于二分类问题（如垃圾邮件判定、疾病诊断）。尽管名字中有“回归”，但它通过数学变换将线性输出映射到概率区间，从而实现分类。

1. 理解数学原理，包括但不限于：
    - Sigmoid函数的形状和作用；

- 交叉熵损失的意义；
- 梯度下降如何更新参数；

2. 从线性回归过渡到逻辑回归。

学习资料

本节内容仍可参见第二节的学习资料，其他资料请大家自行搜寻学习。

一轮考核 任务1 手写代码实现线性回归模型（必做，分值40%）

> “手写代码”指的是不调用其他机器学习库，只使用三大库实现代码。下同。

数据集见群文件insurance.csv，任务是手写代码实现线性回归模型预测医疗保险费用。

数据集的特征介绍
age：年龄
sex：性别
bmi：bmi指数，理想范围为 18.5 到 24.9
children：健康保险覆盖的儿童数量 / 受抚养者数量
smoker：吸烟情况
region：受益人在美国的居住区域，东北、东南、西南、西北
charges：健康保险开出的个人医疗费用

你的任务（代码分值20%，笔记与答辩分值20%）

1. 选择合适的比例将数据集分割为训练集和测试集；（3%）
2. 根据所学知识和你对数据集的理解，进行数据预处理和特征工程；（7%）
3. 利用处理后的数据进行算法模型训练，要求手写线性回归算法预测医疗保险费用；（7%）
4. 结合线性回归问题的评估标准来评估自己实现的算法模型；（3%）
5. 理解线性回归的数学原理，做好笔记，准备好答辩（20%）

一轮考核 任务2 调库代码实现线性回归模型（必做，分值20%）

> “调库代码”指的是不要求手写代码，可使用sklearn等机器学习库（有关这个库和其他机器学习库的用法，请大家自主上网搜索学习）。该部分任务主要考察特征工程，而不是算法；这也是后续大家打比赛中最影响得分的一步。

该任务需要在kaggle打榜（即提交你的模型的预测值在kaggle平台上，平台会自动给你的模型性能进行打分，进行排名）。分值组成：特征工程和打榜10%+答辩10%。

数据集见群文件laptop_prices_train.csv，任务是调库代码实现线性回归模型预测笔记本价格。

提示：如果你的学习进度/考核任务进度卡在了这一部分，请优先完成任务1和3，最后再来完成这个，尝试优化你的特征工程和选用的机器学习算法，以求更好的分数。

数据集的特征介绍

品牌：笔记本电脑的制造商（例如，戴尔、惠普、苹果、华硕、联想）
处理器：CPU 型号，包括英特尔（i3、i5、i7、i9）和 AMD 锐龙（3、5、7、9）
内存（GB）：笔记本电脑的内存大小（例如，4GB、8GB、16GB、32GB、64GB）
存储：存储的类型和大小（例如，256GB SSD、512GB SSD、1TB HDD）
图形处理器：图形处理单元，集成或独立（例如，英伟达 GTX 1650、RTX 3060）
屏幕尺寸（英寸）：以英寸为单位的显示屏尺寸（例如，13.3 英寸、14 英寸、15.6 英寸、17.3 英寸）
分辨率：屏幕分辨率，如 1366x768、1920x1080、2560x1440 或 3840x2160
电池续航时间（小时）：估计的电池续航时间，范围为4 到12 小时
重量（千克）：笔记本电脑的重量，在 1.2 千克到 3.5 千克之间
操作系统：预装的操作系统，包括 Windows、macOS、Linux 和 FreeDOS
价格（美元）：目标变量，表示笔记本电脑的价格（以美元为单位）

你的任务

1. 根据所学知识，按照一定步骤利用调库代码实现线性回归算法建立模型；（5%）
2. 在平台上下载测试集，利用训练好的模型预测测试集中样本的笔记本价格，按照一定模板填充你的预测结果上传到平台上，平台会自动给你的结果打分；（5%）
3. 着重上述过程中的特征工程，做好答辩的准备（10%）

如何打榜

1. 进入链接https://www.kaggle.com/t/75b77ad11a424afc8c222be23e6b34f7，然后注册登录后进入比赛界面，点击右上角加入比赛；
2. 从群文件或者上方的Data下载训练集laptop_prices_train.csv，训练好模型后使用群文件中laptop_prices_test.csv的数据预测每个样本的笔记本价格，将结果填充到群文件模板submission.csv；
3. 在右上角提交预测处提交你的submission.csv文件，系统会自动打分，评价指标为R^2。

一轮考核 任务3 手写代码实现逻辑回归模型（必做，分值40%）

数据集见群文件startup_data.csv，任务是手写代码实现逻辑回归模型判断创业公司是否能盈利。

数据集的特征介绍

创业公司名称：创业公司的名称（例如，Startup_1、Startup_2）
行业：创业公司所经营的领域（例如，人工智能、金融科技、健康科技）
融资轮数：创业公司进行的融资轮总数（1-5）
融资金额（百万美元）：以百万美元为单位的融资总额
估值（百万美元）：创业公司的投后估值以百万美元为单位
收入（百万美元）：以百万美元为单位的估计年收入

员工人数：在创业公司工作的员工人数（从 5 到 5000 不等）
市场份额（%）：创业公司所占据的市场百分比
盈利： 一个二元指标（1 = 盈利，0 = 不盈利）

你的任务（代码分值20%，笔记与答辩分值20%）

1. 选择合适的比例将数据集分割为训练集和测试集；（3%）
2. 根据所学知识和你对数据集的理解，进行数据预处理和特征工程；（7%）
3. 利用处理后的数据进行算法模型训练，要求手写逻辑回归算法判断公司是否能盈利；（7%）
4. 结合逻辑回归问题的评估标准来评估自己实现的算法模型；（3%）
5. 理解逻辑回归的数学原理，做好笔记，准备好答辩（20%）

一轮考核 附加任务 （选做，加分25%）

附加任务1 多分类softmax回归模型（10%）

数据集见群文件Iris.csv，任务是手写代码实现softmax模型判断每个样本的鸢尾花品种。

数据集的特征介绍

花萼长度（厘米）
花萼宽度（厘米）

花瓣长度（厘米）

花瓣宽度（厘米）

品种

你的任务

1. 利用处理后的数据进行算法模型训练，要求手写softmax算法判断每个样本的鸢尾花品种并评估性能；（5%）
2. 理解数学原理，做好笔记，准备好答辩（5%）

附加任务2 决策树c4.5分类问题（5%）

数据集见群文件startup_data.csv。

你的任务

1. 利用处理后的数据进行算法模型训练，要求手写决策树c4.5算法判断公司是否能盈利并评估性能；（3%）
2. 理解数学原理，做好笔记，准备好答辩（2%）

附加任务3 朴素贝叶斯分类问题（5%）

数据集见群文件startup_data.csv。

你的任务

1. 利用处理后的数据进行算法模型训练，要求手写朴素贝叶斯分类算法判断公司是否能盈利并评估性能；（3%）
2. 理解数学原理，做好笔记，准备好答辩（2%）

附加任务4 k-means聚类问题（5%）

数据集见群文件startup_data.csv。

你的任务

1. 利用处理后的数据进行算法模型训练，要求手写k-means聚类算法判断公司是否能盈利并评估性能；（3%）
2. 理解数学原理，做好笔记，准备好答辩（2%）